



AI 芯片服务器产业链深度剖析

作者：开卷有财

摘要

AI 芯片服务器，作为承载大模型训练与推理的**核心物理实体**，已从传统的通用计算基础设施中分化，演变为由专用加速芯片定义、软硬件深度协同的**战略级产业**。本报告系统解构其产业链，核心结论如下：当前产业正处**爆发式成长期**，技术快速迭代与地缘政治因素交织，驱动价值链条剧烈重构。**上游芯片环节凭借极高的技术壁垒和生态控制力，占据了价值链的绝对高地**，其中又以掌握先进制程、CoWoS 封装和 HBM 内存的“系统定义者”为甚。与此同时，**国产替代从“可用”向“好用”的攻坚**，以及液冷、高速互联等使能技术的创新，正在催生结构性的新阿尔法机会。基于对超过 20 家核心公司的矩阵化分析，我们明确：投资应首选兼具**确定性与高弹性**的国产算力系统定义者及关键“卖铲人”，并积极跟踪技术路径突破带来的赛道切换机遇。

第一部分：主题界定与驱动力

1. 主题定义

AI 芯片服务器特指以 GPU、ASIC 等异构加速芯片为核心，专为处理人工智能（尤其是深度学习）训练与推理工作负载而设计的高性能服务器系统。其核心边界在于：**硬件上**，区别于以 CPU 为核心的通用服务器，强调加速卡的算力密度、互联带宽与能效比；**生态上**，与 NVIDIA CUDA、华为 CANN 等专用软件栈深度绑定，构成软硬一体的闭环。

2. 核心驱动力

- **技术突破与市场定义**：大模型参数量呈指数级增长（已突破 10 万亿级），直接催生对算力“暴力”需求。以 NVIDIA Blackwell 架构为例，其单卡算力突破 3000 TOPS，并通过 NVLink 6.0 实现千卡级无损互联，**持续定义市场技术标准与采购节奏**。技术演进已从单纯拼算力，转向追求“有效算力”，即算力利用效率。
- **政策强力推动与国产替代**：全球主要经济体将算力视作国家竞争力核心。在国内，“自主可控”政策强力驱动国产替代进程。TrendForce 预测，2025 年外购（NVIDIA/AMD）芯片在中国 AI 服务器中的占比将从 2024 年的约 63%骤降至约 42%，而本土芯片（含 CSP 自研 ASIC）占比将跃升至 40%，几乎平分秋色。这构成了国内产业链发展的“**确定性**”主线逻辑。
- **重大成本拐点与能效约束**：单芯片功耗迈向 1000W 大关，使得传统风冷方案濒临失效，液冷技术从可选变为必选，渗透率已超 65%。能效（PUE）与总拥有成本（TCO）成为下游采购的关键决策因素，**倒逼散热、供电等基础设施环节技术革新**。

- **应用场景从云到边全面爆破**：驱动力量从早期的互联网巨头模型训练，扩展至金融、制造、政务、医疗等行业的推理应用，以及自动驾驶、机器人等边缘场景，形成多层次、差异化的算力需求金字塔。

第二部分：产业链解构与技术路径图

1. 产业链图谱

AI 芯片服务器产业链呈现纵向整合加深、横向专业分化的特点。

- **上游（核心硬件与软件）**：构成价值核心。
 - **计算芯片**：GPU（英伟达、AMD、沐曦、摩尔线程）、ASIC（谷歌 TPU、华为昇腾、寒武纪、CSP 自研芯片）、FPGA。
 - **存储**：HBM（三星、SK 海力士、美光）、高带宽 DDR5 内存、企业级 SSD（特别是为 AI 推理设计的 Nearline SSD）。
 - **互联**：InfiniBand/以太网交换芯片、800G 光模块、NVLink 等专用互联技术。
 - **关键组件**：高端 PCB（如载板）、先进散热（液冷）、高功率电源。
 - **基础软件**：CUDA、ROCm、昇思 MindSpore 等异构计算平台；PyTorch、TensorFlow 等 AI 框架。
- **中游（系统集成与交付）**：
 - **品牌服务器厂商**：提供完整软硬件解决方案，如浪潮信息、新华三、联想、华为、超聚变等。根据 IDC 数据，2025 上半年中国加速服务器市场中，浪潮、新华三、联想占据近 50% 的销售份额，市场集中度高。
 - **ODM/OEM 厂商**：如工业富联、广达、纬创，为云服务商（CSP）提供定制化白牌服务器。
- **下游（算力运营与应用）**：
 - **算力服务商**：公有云厂商（AWS、阿里云、腾讯云）、智算中心运营商、电信运营商（构建算力网络）。
 - **行业用户**：互联网（占据中国市场近 69% 份额）、金融、政府、制造、教育、医疗等。

2. 关键技术与工艺路径

当前并存的核心技术路线围绕 “计算效率” 与 “生态主导权” 展开竞争。

- **芯片架构路线**：
 - **GPU（通用并行计算）**：以 NVIDIA 为主导，凭借数十年构建的 CUDA 生

态护城河，在通用 AI 训练市场占据绝对主导（全球 AI 服务器 GPU 市占率超 90%）。其技术路径持续迭代通用计算核心与专用张量核心（Tensor Core）。

- **ASIC（专用集成电路）**：包括两大分支：1）云巨头自研 ASIC（如谷歌 TPU、AWS Trainium），旨在优化特定工作负载的 TCO，摆脱对单一供应商依赖；2）**第三方 ASIC**（如华为昇腾、寒武纪），寻求在国产替代或特定场景（如推理）中实现更高能效比。ASIC 胜在**极致性能和能效**，但挑战在于**高昂的研发成本、有限的编程灵活性以及生态构建**。
- **国产 GPU/加速芯片路线选择**：
 - ◆ **全功能 GPU 路线**：以**摩尔线程**为代表，追求兼容图形渲染与通用计算，试图构建类 CUDA 的广泛生态，技术挑战与投入最大。
 - ◆ **高性能计算 GPU 路线**：以**沐曦股份**为代表，聚焦数据中心 AI 与 HPC，简化图形单元，追求在核心算力上实现突破，其技术路径与 AMD 更为接近。
 - ◆ **专用 AI 芯片路线**：以**寒武纪**为代表，其 MLU 架构为 AI 原生设计，在特定模型上能效表现突出，属于“特种部队”。**海光信息**则走 x86 CPU+兼容 CUDA 生态的 DCU 路线，强调“好用”与平滑迁移。
- **使能技术路线**：
 - **散热**：**冷板式液冷**已成为当前高密度 AI 服务器的主流和默认选择（占比超 60%），正逐步向**浸没式液冷**等更高效的直接接触方案演进。
 - **互联**：**InfiniBand**在超大规模集群中仍保持性能优势，但基于**RoCEv2 的增强以太网**方案正在快速追赶，性能差距已缩小至个位数百分比，其开放性和成本优势对 CSP 吸引力巨大。

3. 价值链“微笑曲线”识别

- **核心环节（高附加值、强壁垒）**：
 - a) **加速芯片设计与生态软件**：位居价值链最顶端。尤其是具备**系统定义能力**的厂商（如英伟达），通过“芯片+互联+软件栈”的垂直整合，攫取产业链大部分利润。其壁垒在于**万亿晶体管级芯片设计、先进制程/封装（CoWoS）供应、以及十年积累的软件生态**。
 - a) **HBM 等尖端存储**：HBM 与 GPU 通过 CoWoS 封装形成 2.5D/3D 集成，技术壁垒极高，目前由三星、SK 海力士、美光三巨头垄断，**供需长期紧张，毛利率丰厚**。
 - a) **关键“卖铲”环节**：包括 CoWoS 等先进封装产能、用于芯片制造的 EUV 光刻机等。这些是产业扩张的关键瓶颈，供应商享有极强的议价权。

- **关键瓶颈环节（供需失衡，享阶段性溢价）：**
 - a) **先进封装（CoWoS）产能：** 尽管 2025 年紧张状况将有所缓解，但仍是制约高端 AI 芯片（尤其是 HBM 版本）放量的主要瓶颈之一。
 - a) **高效液冷解决方案：** 随着单机柜功率密度突破 50kW 甚至 120kW，能够提供可靠、低 PUE 液冷方案（特别是冷板、快速接头、CDU 等）的厂商，在需求爆发期将获得显著溢价。

第三部分：价值量分布与动态演变分析

1. 静态价值分布

- **市场规模：** 2025 年，全球 AI 服务器市场规模预计达 **3000 亿美元**（年增 46.1%），占整体服务器市场总值的 72%。中国加速服务器市场规模将超过 2000 亿元人民币。其中，AI 芯片是最大价值组成部分。
- **毛利率区间估算：**
 - **设计环节：** 领先的芯片设计公司（如英伟达）毛利率可达 70% 以上；国产芯片厂商因处于追赶期且规模较小，毛利率波动较大，部分领先企业正由负转正。
 - **存储环节：** HBM 毛利率显著高于标准存储产品。
 - **品牌服务器/ODM 环节：** 毛利率通常为 15%-25%，其中集成液冷、高端互联等方案的高端机型毛利率更高。
 - **散热/电源等组件：** 液冷等新技术方案毛利率可达 30%-40%，传统风冷组件毛利率较低。

2. 动态价值迁移

- **技术迭代驱动的价值重构：**
 - **ASIC 化趋势：** 若 CSP 自研 ASIC 或第三方 ASIC 在更多场景取得突破，价值将从通用 GPU 芯片商部分迁移至 **ASIC 设计服务、IP 授权及配套编译软件公司**。英特尔成立 ASIC 与设计服务部门正是看中此趋势。
 - **“存算一体”、“光计算”等颠覆性技术：** 虽然中长期才有望规模化，但其一旦成熟，将彻底重塑现有以存储墙和功耗墙为特征的产业链，价值将向掌握新物理原理和集成技术的公司转移。
- **产业化进程中的需求弹性：**
 - **从实验室到量产：** 在芯片设计定型后，对先进封装（CoWoS）、HBM、测试设备的需求弹性最大。
 - **从量产到大规模部署：** 对液冷基础设施（CDU、管路、冷板）、高速互联

设备（800G 光模块、交换芯片）、高功率电源的需求呈现爆发式增长。例如，液冷渗透率从 2024 年的快速提升到 2025 年成为默认配置，相关公司业绩弹性极大。

- 供需格局带来的阶段性溢价：
 - 短期瓶颈：除了前述的 CoWoS 和 HBM，2025-2026 年，面向 AI 推理的 Nearline SSD（企业级 QLC SSD）因替代传统 HDD 的需求激增，预计将出现供应紧张，相关存储厂商受益。
 - 产能区域性重构：地缘政治促使国内建立自主产能，从芯片制造到服务器组装的本土化供应链企业，将在国内市场需求中占据更有利位置。
- 国产替代引发的价值转移：
 - 关键“卡脖子”环节：高端 GPU/GPGPU、高性能计算 CPU、EDA 工具、半导体制造设备（如 EUV）是目前国产化率最低、价值转移潜力最大的领域。
 - 价值转移路径：随着国产芯片在政务、运营商、国企及特定行业市场突破（如华为昇腾、寒武纪等），原本流向海外巨头的芯片价值，将转移至本土芯片设计公司、与之深度绑定的国内服务器品牌商、以及适配国产芯片的软件优化与生态服务商。联想创投构建的从寒武纪、海光到沐曦、摩尔线程的投资矩阵，正是对这一价值转移趋势的全面布局。

第四部分：核心公司深度梳理与矩阵定位

1. 构建公司分析矩阵

我们根据 “产业链角色与护城河” 和 “业绩弹性与确定性” 两个维度，将核心公司置于以下四象限矩阵中。投资优先级从第一象限向第四象限递减。

高确定性 / 高弹性 (第一象限)	高确定性 / 低弹性 (第二象限)
角色：国产算力系统定义者、核心瓶颈环节突破者。特征：深度绑定国家战略与关键客户，技术壁垒高，处于需求爆发风口。代表：华为（昇腾）、中科曙光/海光信息（生态与政务市场）、浪潮信息（市场份额龙头）、英维克（液冷龙头）。	角色：成熟环节的国产龙头、生态赋能者。特征：市场地位稳固，增长稳健但爆发力相对平缓，受益于国产替代但格局已定。代表：新华三、联想集团（服务器业务）、部分领先的 PCB/连接器厂商。
低确定性 / 高弹性 (第三象限)	低确定性 / 低弹性 (第四象限)

角色： 技术特色专家、潜在颠覆者。 特征： 在细分技术路径上具备独特优势（如 ASIC、全功能 GPU），若路径成功则弹性巨大，但面临生态、商业化验证等不确定性。 代表： 寒武纪、沐曦股份、摩尔线程。	角色： 标准化组件供应商、尾随者。 特征： 产品差异化低，竞争激烈，在产业链中议价能力弱，业绩增长依赖行业贝塔。 代表： 部分二线服务器组装厂、传统风冷组件厂商。
--	---

注：国际巨头如英伟达、AMD，因其在全球化供应链中的独特地位和极高壁垒，可视为位于一个独特的“全球核心”象限，确定性极高，但对 A 股投资者而言弹性来源不同。

2. 关键公司对比分析表

聚焦矩阵中第一、三象限的重点公司进行分析：

公司名称	产业链环节与核心产品	技术/工艺路径卡位	核心客户/生态绑定	产能与扩产计划	关键财务指标前瞻	核心投资逻辑与近期催化剂
华为（昇腾）	上游芯片/中游服务器/软件全栈。昇腾 910B/910C 芯片，Atlas 服务器。	自研达芬奇架构 NPU，+CANN 软件栈，构建全栈自主闭环生态。技术路径对标英伟达，是国产系统定义者。	深度绑定国内政企、运营商市场。参与多地智算中心建设，与央企、地方国资合作紧密。	通过合作伙伴（如超聚变）进行服务器制造与交付，芯片产能受外部制约但积极寻求突破。	非上市公司，但估算其昇腾产业链相关业务将随国产化政策呈现爆发式增长，毛利率有望提升。	逻辑： 国产 AI 算力无可争议的龙头与“底座”，受益确定性最强。 催化剂： 重大行业信创订单落地；新一代芯片发布；算力网络建设加码。
中科曙光/海光信息	上游芯片（海光 DCU/CPU）/中游服务器（曙光）。	海光 DCU 采用兼容 CUDA 的 GPGPU 路线，生态迁移成本最低，主打“好用”。	海光与曙光协同，在政务、科研、金融等高壁垒行业根基深厚。客户黏性极强。	海光芯片设计，委托制造。曙光服务器产能稳定，可扩产。	海光信息：DCU 放量推动营收高速增长，利润端有望随规模效应显现。曙光：服务器业务稳健增长，利润率保持稳定。	逻辑： “CPU+DCU”协同，在关键行业国产替代中路径阻力最小，业绩确定性高。 催化剂： 海光深算系列新品获大额订单；行业信创采购大单落地。

浪潮信息	中游品牌服务器龙头。AI 服务器、通用服务器及 JDM 模式。	作为集成商，全面适配国内外主流 AI 芯片（英伟达、昇腾、寒武纪等），技术卡位在于大规模交付与运维能力。	中国互联网行业最大供应商（占其营收大头），同时拓展政企市场。与头部 CSP 绑定极深。	供应链管理能力强，产能弹性大，可根据订单快速调整。	营收规模行业第一，但毛利率受上游芯片成本及行业竞争影响。AI 服务器占比提升是毛利率核心驱动。	逻辑：AI 服务器市场份额绝对龙头（近 30%），直接受益于行业贝塔，业绩弹性大。催化剂：互联网公司资本开支超预期；在国产芯片服务器市场份额提升。
寒武纪	上游专用 AI 芯片。思元（MLU）系列训练/推理芯片。	专用 AI 芯片路线，MLUarch 原生 AI 架构，在特定模型上能效比优势显著。软件栈自研，生态独立。	2025 年与国内大型 CSP 进行前期验证后，正逐步推向云市场。在特定行业项目中有应用。	芯片设计公司，产能依赖代工。产品正处于市场拓展关键期。	2025 年上半年首次实现半年度盈利（归母净利润 10.38 亿元），但长期盈利的持续性有待观察，取决于大规模商业化落地。	逻辑：国产 AI 芯片第一股，技术特色鲜明，若其专用路线在 CSP 或特定场景获大规模采纳，弹性巨大。不确定性高。催化剂：与某主流云厂商签订重大供货协议；边缘推理芯片放量。
沐曦股份	上游高性能计算 GPU。曦云 C 系列（训推一体）、曦思 N 系列（推理）。	专注高性能计算 GPU，类似 AMD 路线，首发推理芯片，再攻关训推一体，技术路径清晰务实。	产品已在国家及地方智算平台、运营商实现规模化应用，累计销量超 2.5 万颗。	设计公司，产能依赖代工。IPO 募资用于新一代芯片研发，现金流充裕。	2022-2024 年营收快速增长但持续亏损。预计 2025 年营收 15-19.8 亿元（增 102%-166%），亏损大幅收窄。	逻辑：聚焦数据中心高性能 GPU，产品已获早期客户验证，上市后资金助力研发，处于从“可用”到“好用”的关键爬坡期。催化剂：下一代训练芯片流片成功；在央企采购中获大额订单。
英维克	上游关键组件（温控）。数据中心液冷（冷板、CDU	国内机房温控龙头，全面布局冷板式与浸没式液冷，技术积累深厚，	广泛覆盖互联网、运营商、金融等行业客户，与主流服	积极扩产液冷相关产能，以应对需求爆发。	液冷业务收入占比快速提升，该业务毛利率显著高于传统业务，驱动	逻辑：AI 服务器功耗激增下最确定的“卖铲人”，液冷需求刚性且爆发在即，公司龙头地位确保高业绩弹

	等) 全链条解决方案。	产品线齐全。	服务器厂商均有合作。		公司整体毛利率与净利率上行。	性。 催化剂 ：单季度液冷收入环比大幅增长；获头部 CSP 数据中心液冷大单。
--	-------------	--------	------------	--	----------------	--

3. 龙头引领与外溢效应

- **国际龙头（英伟达）的战略外溢**：英伟达每一代新架构（如 Blackwell，下一代 Rubin）的发布，不仅定义了自身增长，更**同步拉动了其全球供应链**：台积电（先进制程与 CoWoS）、SK 海力士/三星（HBM）、新思科技/楷登电子（EDA）、以及高端散热和电源供应商。其力推的 **NVLink Fusion 开放战略**，旨在将其互联标准扩展到 CSP 自研 ASIC，这将为参与其开放生态的**互联技术与芯片设计服务公司**带来新机遇。
- **国内龙头（华为）的战略外溢**：华为昇腾构建的“硬件+基础软件+应用使能”全栈生态，是其作为国内系统定义者的核心。这为其供应链带来了明确的外溢：**中软国际、软通动力等**（昇腾一体机合作与行业应用开发）；**神州数码、拓维信息等**（华为鲲鹏/昇腾服务器合作伙伴）；以及**海量数据、东方国信等**（基于昇腾底座的数据与 AI 应用服务商）。华为的战略选择，直接定义了国内一大批上市公司的业务方向和估值锚。

第五部分：综合研判与风险提示

1. 投资时钟与阶段判断

AI 芯片服务器主题目前处于 “**成长期**”的早中期。其特点是：**技术快速迭代**（约 1-1.5 年一代）、**市场需求爆发**（年增速>40%）、**竞争格局未定**（尤其在国内外市场，多技术路线并存）、**盈利能力分化**（龙头开始盈利，多数公司仍处投入期）。从下游渗透率看，AI 服务器占整体服务器出货量比重在 2025 年预计为 14.8%，仍有巨大提升空间，远未到成熟期。

2. 标的推荐排序

基于“确定性优先，兼顾弹性”的原则，在当前时点推荐如下：

- **首选（配置核心）**：
 - a) **华为昇腾产业链核心伙伴**：选择与华为绑定深、受益于其生态扩张确定性最强的标的，如**中科曙光**（整机与生态）、**软通动力**（应用与集成）。
 - b) **高景气瓶颈环节龙头**：**英维克**（液冷）。该环节受益确定性不亚于芯片，且竞争格局更优，业绩能见度高。
- **次选（积极布局）**：
 - a) **国产芯片领军者**：**海光信息**（高确定性）、**寒武纪/沐曦股份**（高弹性）。

建议采用组合方式配置，以平衡确定性与潜在超高回报。其中，海光可作为基石仓位。

b) **市场份额领先的服务器厂商：浪潮信息。**直接受益于行业总量扩张，是捕捉行业贝塔的高流动性标的。

● **跟踪（等待催化）：**

a) **技术路径潜在突破者：**密切关注**摩尔线程**全功能 GPU 的生态进展，以及**光计算、存算一体**等前沿技术公司的研发突破。

b) **供应链细分环节专家：**如在高带宽 PCB、先进封装材料、硅光模块等领域实现国产突破的公司，其订单与业绩的兑现需要密切跟踪。

3. 关键风险提示

- **技术路线风险：**国产 GPU/ASIC 的技术路径尚未经历大规模商业化检验，存在产品性能不及预期、生态构建失败的风险。国际技术路线（如存算一体）的突破可能对现有产业链造成颠覆。
- **产业化与供应链风险：**国内先进制程产能扩张不及预期，可能制约国产高端芯片上量。全球 CoWoS、HBM 产能若再次出现严重瓶颈，将延缓整个产业发展。
- **政策与地缘政治风险：**美国对华半导体技术出口管制可能进一步升级，影响国内产业链获取关键设备与技术支持。国际贸易摩擦与关税变化（如潜在的美国新关税政策）将影响全球供应链成本与布局。
- **市场竞争与盈利风险：**国内 AI 芯片市场参与者众多，可能出现**过度竞争和价格战**，导致企业盈利改善迟于营收增长。下游互联网公司资本开支可能受宏观经济影响而波动。